

NASA Verileri ile Lityum-İyon Batarya Şarj Durumu Tahmini

1. Problemin Tanımı ve Amacı

Batarya yönetim sistemlerinde doğru şarj durumu (State of Charge – SOC) tahmini kritik öneme sahiptir. Bu çalışmanın amacı, NASA tarafından sağlanan lityum-iyon pil veri setlerini kullanarak pillerin şarj durumlarını doğru bir şekilde tahmin etmektir. Kullanıcıların istedikleri bataryaları anlık olarak takip edebilmesi ve batarya performansının optimize edilmesi hedeflenmiştir.

2. Veri Seti ve Ön İşleme Adımları

Veri seti MATLAB formatında (.mat) olup, B0005 bataryası üzerinde dönüşümler yapılarak veri ön işleme adımlarından geçirilmiş ve model eğitimi için kullanılmıştır. Literatür araştırmalarına göre SOC ölçümleri genellikle discharge döngüsünde yapılmakta olup, bu yaklaşımın doğruluğu ve güvenilirliği desteklenmektedir.

Öznitelik çıkarımı ve korelasyon analizleri sonucunda tahmin modeli için *voltage_measured*, *current_measured*, *temperature_measured*, *Q_cum_Ah*, *capacity* ve *dV_dt* özellikleri seçilmiştir. Tüm veri ön işleme ve eğitim süreci, *notebooks/preprocess_and_train.ipynb* dosyasında detaylı olarak yer almaktadır.

3. Keşifsel Veri Analizi (EDA) Sonuçları

EDA çalışmaları, veri dağılımları, öznitelik korelasyonlarının belirlenmesini kapsamaktadır. Analizler sonucunda seçilen özniteliklerin SOC tahmininde anlamlı etkileri olduğu gözlemlenmiştir. Her döngüde batarya parametrelerinin nasıl değiştiğini gösteren grafikler çıkarılmıştır.

4. Model Geliştirme Süreci ve Performans Metrikleri

Modelleme aşamasında üç farklı derin öğrenme yaklaşımı kullanılmıştır:

1. LSTM (Long Short-Term Memory):

- Zaman serisi verilerinde uzun dönem bağımlılıkları yakalayabilen bir RNN türüdür.
- Eğitim sırasında erken durdurma (early stopping) uygulanmış, overfitting etkileri gözlemlenmiştir.

- Validation MAE: 1.536

2. GRU (Gated Recurrent Unit):

- LSTM'e benzer şekilde zaman bağımlılıklarını yakalar, ancak daha az parametreye sahiptir ve daha hızlıdır.
- Eğitimde dropout ve early stopping yöntemleri uygulanmıştır.
- Validation MAE: 1.305

3. TimeSeries Transformer:

- Zaman serisi verilerinde self-attention mekanizmasını kullanarak hem kısa hem uzun dönem ilişkilerini öğrenir.
- Early stopping uygulanmış, overfitting diğer modellere göre daha az gözlemlenmiştir.
- Validation MAE: 0.292

Performans Karşılaştırması:

	MAE	RMSE	MAPE	R2
LSTM	1.556891	1.853816	44054.082031	0.995487
GRU	1.324635	1.503459	36058.699219	0.997031
TimeSeriesTransformer	0.632440	0.856557	22666.968750	0.999036

Özet: TimeSeries Transformer modeli, hem MAE hem RMSE açısından diğer modellere kıyasla en iyi performansı göstermiştir. LSTM ve GRU modellerinde eğitim sırasında validation kaybının tekrar artması gözlemlenmiş ve EarlyStopping uygulanmıştır; bu durum **overfitting etkisini** göstermektedir. Yani bu modeller, eğitim verisine çok iyi uyum sağlarken, validation verisi üzerindeki performansları düşmüştür. Transformer modelinde ise EarlyStopping ile overfitting etkisi daha sınırlı kalmış, validation kaybı daha stabil seyretmiş ve tahminler daha güvenilir olmuştur. Bu nedenle final tahminler Transformer modeli üzerinden gerçekleştirilmiştir.

5. REST API Tasarımı ve Demo Uygulaması

Test aşamasında B0006 ve B0018 batarya verileri kullanılarak, MQTT aracılığıyla Dash ve Flask tabanlı bir arayüzde görselleştirme sağlanmıştır. Mevcut sürümde:

- Veritabanı yönetimi
- Görselleştirme ekranı
- MQTT bağlantı bilgisi ekleme ekranı
mevcuttur. Hedeflenen kullanıcı deneyimi, bataryaya özel dashboard oluşturma ve anlık takip olmasına rağmen, bazı teknik kısıtlar nedeniyle bu özellikler eklenememiştir.

6. Docker Entegrasyonu

Tüm proje Docker konteynerleri içinde çalışacak şekilde yapılandırılmıştır. Model eğitimi, veri ön işleme ve Dash/Flask tabanlı arayüz ayrı konteynerlerde çalıştırılabilir. Böylece ortam bağımlılıkları minimize edilmiş, farklı makinelerde hızlı kurulum ve çalıştırma sağlanmıştır. Docker Compose kullanılarak, veri tabanı, model servisi ve web arayüzü tek komutla ayağa kaldırılabilir ve tüm servisler birbirine bağlı şekilde çalıştırılabilir.

7. Üretken AI Araçlarının Kullanımı

Bu projede üretken AI araçları veri setini anlamak ve veri ön işleme adımları için kullanılmıştır.

8. Gerçek Dünya Entegrasyonu Önerileri

- Model, batarya yönetim sistemlerine entegre edilerek gerçek zamanlı SOC tahmini sağlayabilir.
- Edge deployment senaryoları ile bataryaların yerinde izlenmesi mümkün hale getirilebilir.
- MLOps süreçleri ile model güncellemeleri ve sürüm yönetimi otomatik hâle getirilebilir.